

智能体迭代开发文档 (V1 → V2)

项目：双创智能教练 (Entrepreneurial Agent)

迭代范围：V1 (基线版) → V2 (当前版本, Agent 版本 2.1.0)

文档定位：说明 V2 的优化范围**从何而来**、每个问题**如何被验收**、V1/V2 **如何被公平比较**，
以及哪些问题**没有被解决**。

编写原则：本文件中出现的每一个缺陷都来自**真实运行 V1** 的观测结果；每个优化项都配有
影响证据、验收条件与对应测试；未验证的内容一律显式标注。

1. 迭代概述

1.1 本次迭代要解决的核心矛盾

V1 的功能是完整的：三个流程 (F1 理论学习 / F2 项目指导 / F3 评审反馈) 都能跑通，界面可点、
接口有返回。但把 V1 放进课程手册的证据诚信口径下实测后，暴露出一个结构性问题：

V1 的“能跑通”建立在把不确定性悄悄抹平的基础上。

没有来源的陈述被判为事实、明确写着“无来源”的项目拿到 87 分、大模型不可用时日志仍记 success。

对一个面向创新创业课程、要求“结论可追溯、假设可识别”的智能体来说，

这不是体验问题，而是**结论可靠性问题**。

因此 V2 的迭代目标不是“增加功能”，而是**把 V1 中被抹平的不确定性重新变成可见、可审计、可验收的对象**。

1.2 范围取舍原则

原则	含义	在 V2 中的体现
影响优先	只优化“会造成错误结论或触碰诚信红线”的问题	3 个 P0 问题全部纳入；纯展示类问题（如管理员控制台页面）延期
先定测试	先写出“怎样算修好”的校验项，再改代码	tests/common/unified.py 的 U1—U6 输入冻结后才开始改造
版本隔离	每个结论都能回到具体版本，而不是	新增 version.py、GET

	笼统的"V2"	/api/version, 运行日志携带版本快照
同条件比较	V1/V2 必须在相同输入、相同环境下比较	U1—U6 输入逐字照抄手册附录 B, 不因结果不好而替换
人机边界透明	人工改动、绕过、重跑都要留痕, 且不计为 Agent 能力	record_intervention、/api/intervention、日志 human_interventions
证据优于演示	宁可回答得短、承认不知道, 也不补一段听起来合理的市场描述	EVIDENCE_GUARDRAIL 注入三个提示词; F1 未命中概念时只给拆解路径

1.3 一个必须写在前面的诚实说明

本次迭代的 LLM 通道**始终未能验证成功**: DeepSeek API 返回 402 Insufficient Balance, 所有真实模型调用均失败。因此:

- F1、F3 在 V2 中被设计为**以确定性引擎为主路径**, 不依赖 LLM, 其结论是完整有效的;
- F2 以及 rubric_scoring_node 的 LLM 增强层**在本次迭代中从未成功执行**, 只验证了降级路径;
- 本文件中所有关于 LLM 输出的判断, 均标注为"未验证", **不得**作为 V2 的能力证据引用。

详见第 11 节。

2. 优化契约

问题编号沿用优先级前缀: P0 阻断级、P1 严重级、P2 一般级。

2.1 P0 (阻断级)

编号	问题与影响证据	决定	V2 验收条件	对应测试	理由与风险
P0-1	证据分类器默认把无来源陈述判为「事实 F」。workflows.py 的 classify_claims 以 else: label = "F" 兜底, 并给 can_use_now="是"。实测 U2 输入「学校	纳入	① 无来源陈述不得判为 F; ② 明确否定式 ("无来源/没有调研") 不得被当作存在证据; ③ 有来源标记的陈述仍应判为 F (防	U2 (7 项, 含「无来源材料中不出现事实 F 判定」) C-E01 (3) C-E02 (1) C-E03 (4)	直接接触手册证据诚信红线, 属于"结论错误"而非"体验不佳"。 风险 : 判定过严会让正常的项目陈述全部降为 I/H, 故专门设

	支持建立教材交易平台」被判为 F 且可直接采用。		止修复后过度保守)		置 C-E02 反向用例守住区分度。
P0-2	F3 对无证据项目给出 87/100, 且 `evidence_gaps` 为空。根因是关键词匹配否定式失效——输入里的「无来源」字面包含「来源」, 被判定为存在证据; 同一输入还因“创新点是使用 AI”通过了创新维度。	纳入	① 全篇无可定位来源时, 任何维度不超过满分 40%; ② 创新点仅技术堆砌时, 创新维度不超过满分 30%; ③ 确定性引擎总分上限 90%; ④ 证据缺口必须非空; ⑤ 证据充分的对照材料仍应得高分 (≥70 且等级 ≥3)	U5 (6 项, 含「评分未虚高」) C-E04 (5) C-E05 (2)	87 分会让一个空壳项目看起来“基本可用”, 是评审流程最严重的失真。 风险: 门槛参数 (40%/30%) 为工程取值, 尚未经大样本校准。
P0-3	DeepSeek API 返回 402, 所有 LLM 调用静默失败; F2 降级到本地规则, 但日志仍记录 `status:"success"`; 且 `next_task` 恒为空字符串 (本地兜底回复里没有可被 `_extract_task` 解析的任务段落)。	纳入	① 降级运行必须记为 <code>degraded</code> 而非 <code>success</code> ; ② 降级原因可读; ③ 降级下 F2 仍输出完整的五段结构并给出唯一 <code>next_task</code> ; ④ 修订类输入走独立分支	U3 (5 项, 含「给出唯一的下一步任务」) U4 (4) C-X-01 (4)	日志失真使“失败运行没有被隐瞒”无法自证; <code>next_task</code> 为空则 F2 的核心交付物消失。 风险: 本地分支的输出质量低于 LLM 分支, 降级模式下的学生体验尚未经真实用户验证。

2.2 P1 (严重级)

编号	问题与影响证据	决定	V2 验收条件	对应测试	理由与风险
P1-4	F1 理论学习 `theory_response` 只有 2 个硬编码概念分支 (“问题—解决方案匹配”与“证据边界”), 问	纳入	① 知识库收录概念 ≥12 条; ② 13 个常见概念 (含“波特五力”“单位经济”“竞争壁垒”等) 全部命中; ③ 未命中时返回拆解路径而非编造定义	U1 (6 项, 含「概念命中本地知识库 (非兜底)」) C-F1-01	F1 是学生使用频率最高的入口, 兜底文本会让整个流程显得不可用。 风险: 知识库内容为课程自编, C-F1-02

	「波特五力模型」会落到通用兜底文本。			(2)	仅保证其 不声称 外部来源，不代表概念表述的学术权威性。
P1-5	提示词中零处提及 F/I/H/S 证据标注、零处禁止编造引用 ，反而强制要求「Evidence Used 必须包含【知识图谱案例/超图节点数据】的支撑！」——在检索为空时会诱导模型编造案例名。	纳入	① 三个面向学生内容的提示词均注入 EVIDENCE_GUARDRAIL；② 强制引用条款改为“检索为空时如实说明，禁止编造”；③ F1 正文不得出现书名号或 URL	U1（「正文未编造文献/链接」） U3（「不得擅自补齐事实」） C-F1-02（2）	强制引用 + 空检索 = 结构化诱导幻觉，属于设计缺陷而非模型缺陷。 风险 ：提示词约束的有效性 依赖 LLM 可用 ，本次未能实测，只能通过代码审查确认条款存在。
P1-6	运行日志字段不全 ：仅有 run_id、flow 等少数字段，缺 agent_version、git 提交号、model、project_version、duration、human_interventions。手册「日志与可观测性」表要求身份/时间/状态/行为/异常/人机边界/保护七类字段。	纳入	① 七类字段齐备；② 日志写入前脱敏；③ 运行状态可区分 success / degraded / failed	C-L-01（5 组字段完整性） C-S-01（2，脱敏）	没有身份字段就无法证明“第三阶段用的是哪个版本”；没有人机边界字段就无法区分 Agent 能力与人工成果。 风险 ：running、cancelled 两个状态在文档字符串中列出但未定义常量（见第 11 节）。
P1-7	无版本接口 ，无法证明第三阶段用的是哪个 V2 版本。	纳入	GET /api/version 返回 agent_version、agent_stage、prompt_version、kb_version、model、git_commit、git_dirty	C-L-02（5） 测试报告头部版本快照	版本不可定位会让所有对比结论失去锚点。 风险 ：当前 V2 改动尚未提交（git_dirty=true），提交号 9f3236d 实际指向 V1， 必须在终期提交前打标签 。
P1-8	无 `tests/` 目录 ，没有统一测试集，无法产出可复现的自测试证据。	纳入	① tests/common/unified.py 冻结 U1—U6；② tests/custom/project_tests.py 提供组内回归用例；③ tests/run_tests.py 一键运行并输出 JSON + Markdown 报告	全部 77 项校验 报告落盘 tests/reports /	没有测试集时，“已修复”只是口头承诺。 风险 ：自测存在自证偏差，只覆盖已识别的问题，需引入外部视角补充。
P1-9	F1/F3 无会话归属 ，教师端看不到这两个流程的使用记录。	延期	（见第 3 节）	无	真实状态：TheoryRequest、ReviewRequest 至今

					不含 <code>session_id</code> 字段, <code>/api/learn</code> 、 <code>/api/review</code> 不写入 <code>run["session_id"]</code> , 教师看板 <code>aggregate_class_data</code> 仅聚合 F2 会话。本项未完成, 不得计为已修复。
--	--	--	--	--	---

2.3 P2 (一般级)

编号	问题与影响证据	决定	V2 验收条件	对应测试	理由与风险
P2-10	<code>`main.py`</code> 硬编码教师与管理员明文口令 (含管理员默认口令 <code>Admin2026@</code>) , 违反「代码、配置和日志中不存在 API 密钥或不必要个人信息」。	纳入	① 口令仅从 <code>TEACHER_ACCOUNTS</code> / <code>ADMIN_ACCOUNTS</code> 环境变量读取; ② 未配置时生成一次性随机口令并 <code>WARNING</code> 提示; ③ 日志中不出现密钥与手机号	<code>C-S-01</code> (2) 代码审查 + <code>.env.example</code>	明文口令属于交付物自检项中的硬性红线。 风险 : 环境变量中的口令仍是明文存储, 未引入哈希, 属可接受的课程级取舍。
P2-11	前端 <code>stale-file bug</code> : <code>student.js</code> 切换流程时不清空 <code>currentFile</code> , 在 F2 选文件后切到 F3 发送, 会走 <code>/api/upload</code> 却按 F3 渲染, 界面显示「评审结果: <code>undefined/100</code> 」。	纳入	① 发送后清空 <code>currentFile</code> ; ② 切换流程时清空已选文件与预览	无自动化测试 , 人工回归 + 代码走查 (<code>student.js:231</code> 发送后置 <code>currentFile = null</code>)	界面显示 <code>undefined/100</code> 会让学生误认为评审失败。 风险 : 前端无可自动化回归手段, 本项验收强度低于其他项, 列为剩余风险 。
P2-12	<code>`rubric_scoring_node`</code> 从未接入 workflow, <code>rubric_scores</code> 恒为空、教师批改报告操作空数据; 且该节点的 LLM 调用没有 <code>try/except</code> , 一旦接线就会击穿请求。 <code>docstring</code> 提到的	纳入	① 通过 <code>POST /api/score</code> 独立接入 (不塞进 F2 线性流程); ② 节点内 LLM 调用包 <code>try/except</code> , 失败时只输出证据引擎底分; ③ 路由层异常返回 503 并如实	自动化覆盖不足 : 仅 U6 间接覆盖 LLM 不可用路径, <code>/api/score</code> 无专用用例	接入方式是"独立接口"而非"每轮对话跑九维评分", 避免 F2 延迟爆炸。 风险 : 独立接口无自动化用例, 属明显测试盲区。

	<code>competition_node</code> 根本不存在。		说明；④ <code>docstring</code> 更正，删除不存在的 <code>competition_node</code>		
P2-13	<code>`/admin`</code> 路由在 <code>`admin.html`</code> 缺失时静默回退到教师页面，造成"存在管理员控制台"的误解。	纳入	<code>admin.html</code> 缺失时返回 HTTP 501 并列出可用的管理 API 与教师控制台地址，不再回退	无自动化测试，人工验证	静默回退会让使用者误判系统能力边界。 风险 ：仅修正了"如实报错"，管理员控制台页面本身仍未实现（见第 3 节）。

3. 明确延期的项目

以下问题**本次迭代不做**，并说明理由与已知遗留影响。延期不等于不重要，而是"在当前证据与资源条件下，做了反而更糟"。

延期项	具体说明	理由	遗留影响（已知并接受）
D-1: F1/F3 会话归属 (P1-9)	未给 <code>/api/learn</code> 、 <code>/api/review</code> 增加 <code>session_id</code> ，教师端仍看不到这两个流程的使用记录	需要对前端、会话存储、教师看板三处联动改造；在 LLM 通道不可用、F2 本身仍需验证的前提下，优先保证已纳入项的质量	教师端只能看到 F2 的使用情况， F1/F3 的教学使用数据缺失 。本项在契约中标记为"延期"， 不计入本次优化成果 。
D-2: 不做全网检索 / 实时抓取	V2 不接入任何联网检索或外部数据库，F1/F3 的证据来源完全来自本地知识库与输入材料	① 联网检索会引入不可复现的外部状态，破坏"同条件比较"；② 检索结果仍可能被错误标注为 F，反而放大 P0-1 的同类风险；③ 课程场景下，学生应自己补齐来源，而不是由 Agent 代取	F1 未收录的概念只能给拆解路径，不能给权威定义；F3 无法主动核验材料中的数字。 这两个限制被写入输出的 <code>`source_note`</code> / <code>`integrity_note`</code> ，对学生可见。
D-3: 不做真实用户调研	未进行真实问卷、访谈、订单或其他一手数据采集	超出课程周期与伦理审查范围；且一旦采集，数据的真实性责任应由项目团队承担，不能由 Agent 代劳	所有涉及用户意愿、付费能力的结论在系统内一律标为 H 假设 ，不得作为结论依据。手册附录 A 的证据台账已按此口径编写。

D-4: 管理员控制台页面 (P2-13 的完整形态)	仅把 <code>/admin</code> 改为如实返回 501, 未实现 <code>frontend/admin.html</code>	管理员 API (全局看板、用户管理) 已可用, 页面属纯展示层; 在核心流程尚未完成外部验证前投入页面开发的收益最低	管理员需通过 API 直接操作, 无可可视化控制台。已在 501 响应体中列出可用接口与教师控制台地址。
-----------------------------	---	---	--

4. 架构改动说明 (分模块)

4.1 新增模块

模块	行数规模	职责	关键设计
<code>`evidence.py`</code>	约 240 行	保守的证据边界引擎: 把材料切分为可判定陈述并标注 F/I/H/S	判定顺序 <code>S</code> 模拟 → 无来源数字 → <code>I</code> 推断 → <code>H</code> 假设 → <code>F</code> 事实 (需来源标记) → <code>I</code> 兜底; <code>is_negated</code> 实现否定感知 (否定词与关键字允许 8 字符距离); 来源词表刻意排除裸「据」「报告」「通知」「统计」, 避免误命中; 每条判定附带 <code>reason</code> 与 <code>verification_step</code>
<code>`knowledge.py`</code>	约 430 行	F1 本地概念知识库, 共 13 个词条	每词条显式声明来源状态 (<code>reference</code> 字段); <code>lookup()</code> 未命中时返回 <code>FALLBACK</code> , 即通用拆解路径而非编造定义; 无任何词条声称外部链接来源
<code>`version.py`</code>	约 85 行	版本快照单一可信来源	<code>AGENT_VERSION=2.1.0</code> 、 <code>PROMPT_VERSION</code> 、 <code>KB_VERSION</code> ; 通过 <code>git rev-parse</code> 读取提交号并检测工作区脏状态 (<code>git_dirty</code>), 脏状态下明确提示"提交号不能单独作为版本凭证"
<code>`tests/`</code>	3 个文件	统一测试集与运行器	<code>common/unified.py</code> (U1—U6, 输入冻结)、 <code>custom/project_tests.py</code> (13 个组内回归用例, 每个

			声明 <code>regression_of</code>) 、 <code>run_tests.py</code> (一键运行, 输出 JSON + Markdown)
--	--	--	--

4.2 重写模块

模块	V1 状态	V2 改动
<code>`workflows.py`</code>	关键词命中即给分; <code>classify_claims</code> 以 <code>else: label = "F"</code> 兜底; F3 无证据门槛	F3 改为 证据门槛约束的评分引擎 : 五维度权重 20/20/20/25/15 (与手册"项目成果 100 分"表一致); 全篇无来源时任何维度不超过满分 40%; 创新点仅技术堆砌时创新维度不超过 30%; 确定性引擎上限 90%; 新增 <code>_strip_instructions</code> 剔除指令性语句 (否则"请给出证据缺口"会被当成项目自己写了缺口分析)
<code>`observability.py`</code>	仅记录 <code>run_id</code> 与 <code>flow</code> , 降级后仍记 <code>success</code>	七类字段齐备; <code>redact()</code> 脱敏 (API Key、Authorization、token、中国大陆手机号); <code>mark_degraded()</code> 标记降级; <code>finish_run()</code> 在 <code>status=success</code> 且 <code>degraded=True</code> 时自动改写为 <code>degraded</code> ; <code>record_intervention()</code> 记录人工干预
<code>`prompts/coach_prompt.py`</code>	零处提及 F/I/H/S, 零处禁止编造引用, 反而强制要求引用案例名	新增共享常量 <code>EVIDENCE_GUARDRAIL</code> 并注入三个面向学生内容的提示词 (Tutor / Coach / Competition Advisor); 把"必须引用案例"改为"检索为空时如实说明, 禁止编造"
<code>`main.py`</code>	硬编码口令; 无版本/评分/干预/运行记录接口	口令改为环境变量 + 未配置时随机口令; 新增 <code>GET /api/version</code> 、 <code>POST /api/score</code> 、 <code>POST /api/intervention</code> 、 <code>GET /api/runs</code> 、 <code>GET /api/runs/{run_id}</code> ; <code>/admin</code> 改为如实返回 501

<code>`graph/nodes.py`</code>	F2 降级回复中无结构化任务段落, <code>next_task</code> 恒为空	降级输出改为结构化完整输出 (Project Stage / Current Diagnosis / Evidence Used / Impact / Next Task) , 新增修订场景分支 <code>_local_revision_reply</code> ; <code>rubric_scoring_node</code> 的 LLM 调用补 <code>try/except</code> ; docstring 更正 (删除不存在的 <code>competition_node</code>)
-------------------------------	--	--

4.3 未改动但需要说明的模块

- `hypergraph/` (超图规则引擎、证据检查器、评分下限引擎) : 本次未改。 `rubric_scoring_node` 的 Phase 1 底分仍由 `compute_score_floors` + `check_evidence_gaps` 提供, 属**确定性**计算, 不受 LLM 余额影响。
- `graph/workflow.py`: F2 仍为 extractor → critic → coach 三节点线性流程, `rubric_scoring_node` **不在其中** (这是有意设计, 见 P2-12) 。

5. 三个流程的完成定义与独立性

5.1 完成定义

流程	输入	主路径	完成定义 (缺一不可)	依赖 LLM?
F1 理论学习	一个概念或学习目标	本地知识库 (<code>knowledge.py</code>)	① 定义; ② 判断方法; ③ 常见误区; ④ 正例; ⑤ 反例; ⑥ 恰好 3 个 理解检查问题; ⑦ 来源边界声明 (<code>source_note</code>)	否 (<code>ENABLE_LLM_F1=1</code> 时为可选增强, 且增强内容显式标注"未经核验")
F2 项目指导	会话中的多轮文本或上传文档	LLM 主路径 + 规则引擎降级	① 五段结构完整 (Project Stage / Current Diagnosis / Evidence Used / Impact if Unfixed / Next Task) ; ② 恰	是 (降级后仍须满足全部五条)

			好 1 个下一步任务； ③ 任务含 Description / Guideline / Acceptance Criteria；④ 未直接 代写商业计划书；⑤ 降级时如实标注	
F3 评审反馈	项目材料文本	确定性评分引擎	① 五个维度得分与 评分依据；② 证据 缺口清单；③ F/I/H/S 分布；④ 诚 信风险提示；⑤ 可 执行修改建议；⑥ 质量等级（0— 4）；⑦ 评分口径说 明	否

5.2 独立性说明

三个流程在接口层、状态层、降级行为三个层面相互独立：

维度	F1	F2	F3
接口	POST /api/learn	POST /api/chat、POST /api/upload	POST /api/review
会话状态	无状态	必须有 `session_id`（不存在返回 404）	无状态
LLM 不可用时	完全不受影响	降级为规则引擎，输出仍完整	完全不受影响
可否单独验收	可（U1）	可（U3+U4 共用会话）	可（U5）

独立性带来的一个代价必须写清楚：F1/F3 之所以能独立、无状态地调用，正是因为它们**不绑定会话**。

这与延期项 D-1（P1-9）是同一个设计取舍的两面——**独立性换来了可复现性，代价是教师端看不到这两个流程的使用记录。**

另外，U3 与 U4 存在**单向依赖**：U4（指导修订）必须复用 U3 建立的会话上下文，测试运行器因此强制二者按序在同一会话内执行，U4 不单独发起请求。

6. 工程结构、部署与复现说明

6.1 目录结构 (V2 相关部分)

entrepreneurial_agent/	
├─ main.py	# FastAPI 主程序 (V2: 新增 version/score/intervention/runs 接口)
├─ version.py	# 【新增】版本快照
├─ evidence.py	# 【新增】证据边界引擎 (F/I/H/S)
├─ knowledge.py	# 【新增】F1 本地概念知识库 (13 词条)
├─ workflows.py	# 【重写】F1/F2/F3 确定性主路径 + F3 评分门槛
├─ observability.py	# 【重写】七类字段 + 脱敏 + 降级 + 人工干预
├─ prompts/coach_prompt.py	# 【改动】注入 EVIDENCE_GUARDRAIL
├─ graph/nodes.py	# 【改动】F2 降级结构化输出 + 修订分支 + try/except
├─ frontend/static/js/student.js	# 【改动】修复 stale-file bug
├─ tests/	# 【新增】统一测试集与运行器
│ └─ common/unified.py	# U1-U6 (输入冻结)
│ └─ custom/project_tests.py	# 13 个组内回归用例
│ └─ run_tests.py	# 运行器
│ └─ reports/	# 自测试报告 (JSON + Markdown)
├─ logs/runs.jsonl	# 运行记录 (JSONL, 脱敏后落盘)
└─ .env.example	# 环境变量模板 (不含任何真实凭据)

6.2 部署与复现步骤

步骤	命令 / 操作	说明
1. 安装依赖	<code>pip install -r requirements.txt</code>	FastAPI、LangGraph、httpx 等
2. 配置环境变量	<code>cp .env.example .env</code> 后填写	不配置 <code>DEEPSEEK_API_KEY</code> 时 F1/F3 仍完整可用, F2 进入降级模式
3. 配置账号	<code>.env</code> 中设置 <code>TEACHER_ACCOUNTS</code> / <code>ADMIN_ACCOUNTS</code> (JSON 格式)	未配置时系统生成一次性随机口令并在启动日志 WARNING 一次
4. 启动服务	<code>uvicorn main:app --port 8000</code>	端口需显式指定: <code>main.py</code> 内置入口默认 8121, README 示例与测试报告使用 8000, 两者不一致, 复现时务必与实际监听端口对齐
5. 运行测试	<code>python tests/run_tests.py --base http://127.0.0.1:8000 --label V2</code>	报告写入 <code>tests/reports/<label>_<时间戳>.{json,md}</code>
6. 查看版本	<code>curl http://127.0.0.1:8000/api/version</code>	返回版本快照, 含 <code>git_commit</code> 与 <code>git_dirty</code>
7. 追溯运行	<code>GET /api/runs?flow=F3&limit=50</code> <code>GET /api/runs/{run_id}</code>	定位到具体某次运行的完整脱敏记录

6.3 复现性保障

保障项	实现方式
输入可复现	U1—U6 输入在 <code>tests/common/unified.py</code> 中 逐字冻结 ，文件头明确写入"只允许在校验规则上补充，不允许修改 <code>test_input</code> "
输出可复现	F1/F3 走确定性引擎，不因采样随机性在两次运行间漂移
版本可定位	每次运行记录携带 <code>agent_version</code> 、 <code>prompt_version</code> 、 <code>kb_version</code> 、 <code>model</code> 、 <code>git_commit</code>
失败可见	测试运行器 不做任何过滤 ，失败项全部保留在报告中并单列"未通过项与后续动作"
报告可归档	每次运行同时输出机器可读 JSON 与人类可读 Markdown

7. 日志与可观测性（七类字段对照表）

日志以 JSONL 形式追加写入 `logs/runs.jsonl`，写入前所有自由文本均经过 `redact()` 脱敏。

手册要求类别	V2 实际字段	示例 / 说明	由哪个用例校验
身份	<code>run_id</code> 、 <code>agent_version</code> 、 <code>agent_stage</code> 、 <code>flow</code> 、 <code>test_id</code> 、 <code>project_version</code> 、 <code>prompt_version</code> 、 <code>kb_version</code> 、 <code>model</code> 、 <code>git_commit</code>	<code>run_a1b2c3d4e5f6 / 2.1.0 / V2 / F3 / U5</code>	C-L-01、C-L-02
时间	<code>started_at</code> 、 <code>finished_at</code> 、 <code>duration_ms</code> 、 <code>steps[].at</code>	全部为 UTC ISO 8601； <code>duration_ms</code> 为整数毫秒	C-L-01（时间字段完整）
状态	<code>status</code> ∈ { <code>started</code> , <code>success</code> , <code>partial</code> , <code>degraded</code> , <code>failed</code> }	<code>degraded</code> 表示"任务完成了，但不是正常成功"—LLM 失败改用本地引擎时自动写入	C-X-01（须为 <code>degraded</code> 而非 <code>success</code> ）
行为	<code>steps[]</code> ，每项含 <code>at</code> / <code>step</code> / <code>status</code> / <code>detail</code>	如 <code>input_validation</code> 、 <code>agent_workflow</code> 、 <code>rubric_review</code> 、 <code>degrade</code>	C-L-01（行为字段完整）
异常	<code>error_type</code> 、 <code>error_detail</code> 、	仅失败时写入；	C-L-01 间接覆盖

	retry_count	retry_count 由 record_retry() 递增	
人机边界	human_interventions[], 每项含 at / kind / detail	kind ∈ {补充, 修改, 确认, 绕过, 重跑, 纠错}; 非法类型被 POST /api/intervention 拒绝 (400)	C-H-01 (2 项)
保护	redact(): sk-***REDACTED***、api_key=***REDACTED***、authorization=***REDACTED***、token-***REDACTED***、***PHONE***	截断上限默认 300 字符, 换行替换为空格	C-S-01 (2 项)

7.1 本次修复的关键日志缺陷

V1 行为	V2 行为
LLM 调用失败 → 降级到本地规则 → 日志记 status: "success"	mark_degraded() 置 degraded=True; finish_run() 在 status=success 且 degraded=True 时自动改写为 `degraded`
日志只有 run_id 和 flow	七类字段齐备
无人工干预记录位置	record_intervention() + POST /api/intervention + 会话级 human_interventions 列表

8. 必测异常场景

异常测试对应 U6（输入型异常）与 C-X-01（API 型异常），判定标准统一为：

必须返回明确的错误状态与可读说明，不得 2xx 假装成功。

8.1 输入错误

场景	请求	期望	实际（U6 实测）
不支持的文件类型	POST /api/upload, malware.exe	明确拒绝	HTTP 400「仅支持 PDF、DOCX、DOC 或 TXT 文件」
合法扩展名但内容无法解	POST /api/upload, 伪造	明确说明无法提取	HTTP 422「无法提取文件

析	broken.pdf		文本，请检查文件是否为空或为扫描图片」
会话不存在	POST /api/chat, session_id=does-not-exist	明确拒绝	HTTP 404 「会话不存在，请重新开始」
输入超长	POST /api/chat, 4000 字消息	明确拒绝并给出上限	HTTP 400 「消息过长，请控制在 3000 字以内」
评审输入过短	POST /api/review, "太短"	明确拒绝	HTTP 400 「评审至少需要 20 个字符的项目材料」
学习问题为空	POST /api/learn, ""	明确拒绝	HTTP 400 「请先输入一个学习问题」
文件过大	POST /api/upload, >10MB	明确拒绝	HTTP 413 「文件不能超过 10MB」

U6 额外校验：错误信息必须**非堆栈**、**含中文说明**、**长度 ≥6 字符**，确保学生能看懂下一步该做什么。

8.2 API 失败与工具不可用

场景	触发方式	期望行为	实测结果
LLM 余额不足 / 不可用	DeepSeek 返回 402	① F2 降级但仍输出完整五段结构与唯一 next_task; ② 响应体含 degraded=true 与可读 degraded_reason; ③ 运行记录状态为 degraded	通过 (C-X-01 4/4) 。注意：本次迭代全程处于此状态
九维评分 LLM 不可用	/api/score 中 _llm_available() 为假	只输出证据引擎底分 (score_delta=0) , 标记 degraded, 不报错	通过 (rubric_scoring_node 内 try/except + 路由层 mark_degraded)
文档解析失败	上传非文本内容	返回 422 并说明可能原因	通过 (U6)
工作流内异常	任意节点抛错	返回 503 「已有上下文已保留，请稍后安全重试」，不丢失会话上下文	由 /api/chat 的 try/except 保证
版本接口不可达	服务未启动	测试运行器打印错误并返回退出码 2，不产出假报告	通过 (run_tests.py 启动阶段检查)

9. V1/V2 对比方法与结果

9.1 0—4 质量评分锚点

评审结论统一映射到手册规定的 0—4 质量等级（由五维度 0—5 分均值换算，四舍五入并截断到 [0,4]）：

等级	名称	锚点描述
0	不可用	核心结论错误，或存在虚构来源、伪造调研、严重越权建议
1	严重缺陷	多项关键错误；证据不可追溯；需要人工重做大部分内容
2	基本可用	主要结构存在，但需要人工纠正重要错误或补足证据边界
3	良好	核心结论基本正确；来源可定位；事实、推断与假设边界较清楚
4	可靠	结论正确且自洽；证据可追溯；主动暴露不确定性并给出核验路径

9.2 公平比较条件

条件	做法
相同输入	使用手册附录 B 的固定输入（U1—U6）， 逐字照抄，未因结果不好而替换任何一条
相同环境	同一台机器、同一 Python 环境、同一时段、 同样没有可用的 LLM 余额
相同口径	均采用手册"项目成果 100 分"表的五维度权重（20/20/20/25/15）
相同路径	均走确定性引擎路径（F1/F3 不受 LLM 余额影响；F2 两版都在降级模式下比较）
可追溯	V2 结果由 tests/reports/V2_20260913_234752.md 等报告留档，含版本与提交号

9.3 核心对比结果

对比项	V1（修复前）	V2（修复后）	变化
U5 弱项目总分	87/100	23.8/100	下降 63.2 分——从"基本可用"回到"严重缺陷"，与材料的真实证据状态一致

U5 质量等级	未给出等级	1 (严重缺陷)	新增可判定的等级输出
U5 证据缺口	0 条 (evidence_gaps 为空)	15 条	一个明确写着"无来源"的项目不再"没有缺口"
U5 诚信风险	未输出该字段	2 条	显式识别"无来源数字"与"技术堆砌当创新"
证据充分的对照材料	与弱项目几乎无法区分	90.0/100, 等级 4 (可靠)	证明修复是建立区分度, 不是无差别收紧
U2「学校支持建立教材交易平台」	判为 事实 F, can_use_now="是"	判为 I/H, 附带核验动作	消除诚信红线触发点
F2 降级运行日志	status: "success"	status: "degraded" + degraded_reason	失败不再被隐瞒
F2 降级`next_task`	恒为空字符串	非空, 含 Description / Guideline / Acceptance Criteria	降级下核心交付物恢复
F1 概念覆盖	2 个硬编码分支	13 个知识库词条, 未命中给拆解路径	覆盖率提升且不编造定义
测试集	无 tests/ 目录	77 项校验全部通过	从"口头承诺"变为"可复现证据"

9.4 关于对比结论的三点诚实说明

1. **V1 侧只有单点数据, 没有成套可比报告。** V1 没有 tests/ 目录, 77 项测试无法回溯执行, 因此 V1 的 87 分、0 条缺口、status:"success"、空 next_task 均为**当时运行的手工记录与代码走查结果**, 而非同一运行器产出。**V1 与 V2 的对比强度不等价**, 这一点不影响"缺陷真实存在"的判断, 但影响"改进幅度"的精确性。
2. **对照材料在 V1 口径下的数值未单独留档。** 我们只能确证: 在 V2 口径下, 同一份证据充分的材料得 90.0/100 (等级 4), 与弱项目的 23.8 分形成清晰区分。
3. **LLM 路径在两版中都未被比较。** 由于 402 余额问题, V1 与 V2 的 LLM 输出**都没有产生过**, 因此本对比**不构成对 LLM 能力的任何评价**, 只评价确定性路径与工程行为。

10. 测试集说明

10.1 统一测试集 U1—U6 (tests/common/unified.py)

输入取自课程手册附录 B，逐字冻结。

用例	流程	观察重点	校验项数	V2 结果
U1	F1 理论学习	概念正确；层次清楚；正反例有效；有理解检查；不虚构引用	6	6/6
U2	F3-证据边界	不把数字或模拟当事实；分类合理；提出可执行核验；不伪造链接	7	7/7
U3	F2 项目指导	能分步推进；不擅自补齐事实；形成项目骨架；明确待验证项	5	5/5
U4	F2 指导修订	识别受影响模块；不整体重写；保留模拟标识；说明修改理由	4	4/4
U5	F3 项目评审	标准明确；识别虚假/缺失证据；意见具体；评分前后一致	6	6/6
U6	异常与降级	不假装工具成功；错误可见；上下文不丢失；允许安全恢复；日志可定位	7	7/7
		小计	35	35/35

U2 中最关键的一条校验是红线级判定：

「无来源材料中不出现『事实 F』判定」—— 题干已明确"没有提供任何真实来源"，

因此只要有任何一条陈述被判为 F，即判定失败。该用例同时单独复查了 V1 的误判样例

「学校支持建立教材交易平台」。

U5 中最关键的一条是：

「评分未虚高（无来源项目 < 50/100）」—— 直接把 V1 的 87 分情形固化为回归红线。

10.2 组内回归测试 (tests/custom/project_tests.py)

13 个用例，每个显式声明它所回归的缺陷（`regression_of` 字段），使“承诺问题已修复”可直接由测试结果支撑。

用例	名称	类型	回归的缺陷	校验项数	V2 结果
C-E01	证据分类默认值 (无来源不判 F)	local	P0-1: 证据分类器默认判 F	3	3/3
C-E02	有来源陈述判为 F	local	— (防止修复后过度保守)	1	1/1
C-E03	否定感知	local	P0-2 根因: 关键词匹配对否定式失效	4	4/4
C-E04	评审评分门槛	local	P0-2: 无证据项目得到 87 分	5	5/5
C-E05	评审评分区分度	local	— (防止修复后过度收紧)	2	2/2
C-F1-01	F1 概念覆盖	local	P1-4: F1 仅有 2 个硬编码分支	2	2/2
C-F1-02	知识库无编造来源	local	— (证据诚信)	2	2/2
C-L-02	版本可定位	local	P1-7: 无法确认 V2 相对什么版本优化	5	5/5
C-S-01	日志脱敏	local	P2-10: 明文凭证与个人信息	2	2/2
C-X-01	降级透明	http	P0-3: 降级后仍记 success, <code>next_task</code> 为空	4	4/4
C-L-01	日志字段完整性	http	P1-6: 日志仅有 <code>run_id</code> 与 <code>flow</code>	5	5/5
C-H-01	人工干预可追溯	http	P1-6: 人工干预无处记录	2	2/2
C-P-01	本项目材料评审	http	— (大创项目材料自评)	5	5/5
			小计	42	42/42

10.3 合计

U1—U6 共 35 项校验 + 组内 13 个用例共 42 项校验 = 77/77 全部通过。

报告留档: [tests/reports/V2_20260913_234752.md](#) (Agent 版本 2.1.0, git 提交号 9f3236d, 工作区有未提交改动, 模型 deepseek-chat, 耗时 6.1 秒) 。

10.4 测试集的已知不足

不足	说明
覆盖盲区	P2-11 (前端 stale-file) 、 P2-12 (/api/score) 、 P2-13 (/admin 501) 无自动化用例 ，仅有代码走查与人工回归
自证偏差	全部用例由开发者自行设计，只覆盖已识别的问题，缺少外部视角
环境单一	仅在无 LLM 余额的降级环境下执行， 正常 LLM 路径从未被测试覆盖
样本量小	U1—U6 为课程统一集，样本数量有限，评分门槛参数 (40%/30%/90%) 未经大样本校准

11. 剩余风险与未解决问题

以下问题在 V2 中依然存在，如实列出，不作淡化。

#	风险 / 未解决问题	影响	当前状态
R-1	本环境 LLM 余额不可用 (402 Insufficient Balance) , F2 与 `rubric_scoring_node` 始终运行在降级模式	LLM 主路径 (多轮追问的语言质量、九维评分 delta) 从未被验证 ; F2 的实际学生体验可能显著优于或劣于降级输出，目前无从判断	未解决 。降级行为本身已被验证且透明可审计; LLM 路径待余额恢复后补充验证
R-2	F1/F3 无会话归属 (P1-9 延期)	教师端看不到理论学习与评审反馈的使用记录，教学干预缺少这两类数据支撑	未解决 ，已在契约中标记为延期
R-3	B 级来源未取得原始统计口径	证据台账中来自媒体报道转述的比例类数据 (如"亏损面 61.77%" "日均服务约	未解决 。已在大创项目文档附录 A 中逐条标注，并禁止外推

		3 人次") 无法核验原始抽样与统计方法, 只能保留"据报道"限定语	
R-4	V2 改动尚未提交, <code>`git_dirty=true`</code>	版本快照中的 <code>git_commit</code> (9f3236d) 实际指向 V1 , 此时提交号不能单独作为 V2 的版本凭证	待处理 。终期提交前必须完成 commit 并打不可变标签, 否则所有"版本可定位"的结论都站不住
R-5	<code>`observability.py`</code> 文档字符串声明了 7 种状态, 常量只定义了 5 种	<code>running</code> 与 <code>cancelled</code> 在文档中列出但未实现, 长任务的中途状态无法表达	未解决 (实现与文档不一致, 属自证材料中的瑕疵)
R-6	端口配置不一致	<code>main.py</code> 内置入口默认 8121, README 示例与自测试报告使用 8000, 复现时容易连错服务	未解决 (复现步骤中已显式提示需指定端口)
R-7	评分门槛参数未经校准	40% (无来源封顶) / 30% (技术堆砌封顶) / 90% (引擎上限) 为工程取值, 缺少跨项目样本验证	未解决 。当前有 <code>C-E05</code> 守住"不过度收紧", 但参数本身仍可能偏松或偏严
R-8	P2-11 / P2-12 / P2-13 无自动化测试	前端 stale-file 修复、 <code>/api/score</code> 接口、 <code>/admin</code> 501 行为只能靠人工回归, 回归风险高	未解决
R-9	本地知识库为课程自编内容	<code>knowledge.py</code> 的 13 个词条不声称任何外部来源, 其表述的学术权威性未经学科专家审阅	已声明 (<code>C-F1-02</code> 保证不编造来源, 但不保证内容权威性)
R-10	人工干预记录的完整性依赖自觉	<code>/api/intervention</code> 提供记录能力, 但 系统无法强制 学生在改写 Agent 输出时主动登记	未解决 。当前依赖课程流程约束, 而非技术强制

12. 下一阶段建议

按优先级排列, 前 3 项属于"不做就无法进入终期验收"的范畴。

优先级	建议	对应的未解决问题	具体动作
-----	----	----------	------

P0	冻结 V2 版本	R-4	提交当前工作区改动，打不可变标签（如 <code>v2.1.0</code> ），重新运行 <code>tests/run_tests.py</code> 生成 <code>git_dirty=false</code> 的报告。在此之前，任何“版本可定位”的结论都不成立。
P0	恢复 LLM 通道并验证主路径	R-1	充值后重新执行 U3/U4，对比降级与正常模式的输出差异；重点验证 <code>EVIDENCE_GUARDRAIL</code> 是否真的阻止了编造引用（这是 P1-5 唯一未被验证的验收条件）
P0	补齐无自动化覆盖的三项	R-8	为 <code>/api/score</code> 、 <code>/admin501</code> 增加 HTTP 用例；为前端增加最小化的浏览器回归脚本或手工回归清单并留档
P1	完成 F1/F3 会话归属	R-2	三处联动改造：前端传 <code>session_id</code> → 接口写入 <code>run["session_id"]</code> → 教师看板聚合 F1/F3 使用数据
P1	扩大测试输入并引入外部视角	自证偏差	扩充 U1—U6 之外的输入，并请未参与开发的同学按说明试用三个流程，检验是否存在“只对本组输入有效”的过拟合
P1	校准评分门槛参数	R-7	收集 20—30 份真实项目材料，统计五维度得分分布，验证 40%/30%/90% 三个参数是否落在合理区间
P2	统一配置与文档	R-5、R-6	统一端口配置（或改为单一配置源），补齐 <code>running</code> / <code>cancelled</code> 状态常量或修正文档字符串
P2	B 级来源原始口径核验	R-3	对证据台账中的比例类数

			据，尝试获取民政部门或统计机构的原始发布口径；无法获取的，在终期材料中保留"据报道"限定或降级为假设
P2	管理员控制台页面	D-4	实现 frontend/admin.html ，把已可用的管理员 API 可视化
P3	人工干预的技术性提醒	R-10	在前端"复制/改写 Agent 输出"等操作处增加提示，引导登记干预记录

12.1 阶段性结论

V2 完成了本次迭代的全部 **P0 问题**与 **8 / 9 项 P1 问题**、**4 / 4 项 P2 问题**（P1-9 延期），

77 项自动化校验全部通过。最实质的变化不是分数，而是**系统开始如实说出自己不知道什么**：

- 没有再来源不明的"事实"；
- 没有靠否定词蒙混过关的"证据充分"；
- 没有把降级伪装成成功；
- 没有为了让回答显得完整而补出的市场描述。

剩下的风险清单（尤其是 R-1 与 R-4）说明 V2 **还不是一个可以盖棺定论的版本**：

它的确定性路径已经被充分验证，而它的语言生成路径，至今一次都没有真正跑通过。

下一阶段的第一件事，应该是让那条路径真正运行起来。