

自测试报告

被测系统：双创智能教练（Agent V2）

Agent 版本：2.1.0（阶段 V2）

报告标签：Verify

服务地址：http://127.0.0.1:8000

一、测试环境与版本

手册要求：测试结果必须带 Agent 版本、测试编号、时间、模型和项目材料版本，使结论能够回到具体版本与运行记录。

项目	值
Agent 版本	2.1.0
提示词版本	2.1.0
知识库版本	2.1.0
模型	deepseek-chat
git 提交号	9f3236d
工作区存在未提交改动	True
开始时间	2026-09-14T00:07:01.779577
结束时间	2026-09-14T00:07:07.983298
原始结果文件	tests\reports\Verify_20260914_000701.json

⚠ 本次测试时工作区存在未提交改动，因此提交号不能单独作为版本凭证，需与目录快照或压缩包一并留存。

二、质量评分锚点

测试中的主观判定统一采用课程手册的 0—4 质量等级：

分值	等级	判断锚点
0	不可用	核心结论错误，或存在虚构来源、伪造调研、严重越权建议
1	严重缺陷	多项关键错误；证据不可追溯；需要

		人工重做大部分内容
2	基本可用	主要结构存在，但需要人工纠正重要错误或补足证据边界
3	良好	核心结论基本正确；来源可定位；事实、推断与假设边界较清楚
4	可靠	结论正确且自洽；证据可追溯；主动暴露不确定性并给出核验路径

自动化校验项的输出为「通过 / 未通过」，不参与 0—4 打分；0—4 分仅用于

《附录 A》中 F3 评审流程对项目材料的评价结果。

三、结果汇总

本次共执行统一测试集 U1—U6（6 个用例）与组内回归测试（13 个用例），合计 **77** 项校验，通过 **77** 项，通过率 **100.0%**，耗时 6.2 秒。

用例	名称	通过/总数	结果
U1	理论学习	6/6	通过
U2	证据边界	7/7	通过
U3	项目指导	5/5	通过
U4	指导修订（需先执行 U3 建立上下文）	4/4	通过
U5	项目评审	6/6	通过
U6	异常与降级	7/7	通过
C-E01	证据分类默认值（无来源不判 F）	3/3	通过
C-E02	有来源陈述判为 F	1/1	通过
C-E03	否定感知	4/4	通过
C-E04	评审评分门槛	5/5	通过
C-E05	评审评分区分度	2/2	通过
C-F1-01	F1 概念覆盖	2/2	通过
C-F1-02	知识库无编造来源	2/2	通过
C-L-02	版本可定位	5/5	通过
C-S-01	日志脱敏	2/2	通过
C-X-01	降级透明	4/4	通过
C-L-01	日志字段完整性	5/5	通过
C-H-01	人工干预可追溯	2/2	通过

C-P-01	本项目材料评审	5/5	通过
--------	---------	-----	----

四、统一测试集 U1—U6 逐项结果

测试输入取自课程手册附录 B，逐字照抄，未做任何删减。

原始输入被完整保留在 `tests/common/unified.py` 中，冻结后不得修改。

U1 理论学习

观察重点：概念正确；层次清楚；正反例有效；有理解检查；不虚构引用

校验项	结果	证据
概念命中本地知识库（非兜底）	通过	title=问题—解决方案匹配
给出正例	通过	
给出反例	通过	
恰好 3 个理解检查问题	通过	实得 3 个
说明来源边界	通过	本词条为课程自编的概念解释，未引用外部文献；若需写入正式材料，请自行补充可核验来源。
正文未编造文献/链接	通过	未发现

U2 证据边界

观察重点：不把数字或模拟当事实；分类合理；提出可执行核验；不伪造链接

校验项	结果	证据
拆出至少 4 条陈述	通过	实得 6 条
无来源数字「80%」标为 H	通过	labels=['H', 'I', 'H', 'S', 'S', 'I']
模拟内容标为 S	通过	labels=['H', 'I', 'H', 'S', 'S', 'I']
无来源材料中不出现「事实 F」判定	通过	labels=['H', 'I', 'H', 'S', 'S', 'I']
包含「学校支持建立教材交易平台」且未误判为 F	通过	该条为旧版误判为 F 的样例
每条都给出核验动作	通过	
说明当前能否采用	通过	

U3 项目指导

观察重点：能分步推进；不擅自补齐事实；形成项目骨架；明确待验证项

校验项	结果	证据
未直接生成完整商业计划书	通过	回复未出现计划书章节结构
给出唯一的下一步任务	通过	next_task 长度 233
围绕用户/场景/问题推进	通过	
标注证据类型 F/I/H/S	通过	
不擅自补齐事实（检索为空时如实说明）	通过	

U4 指导修订（需先执行 U3 建立上下文）

观察重点：识别受影响模块；不整体重写；保留模拟标识；说明修改理由

校验项	结果	证据
识别受影响模块（场景/替代方案/价值主张/风险）	通过	
保留模拟标识，不把教师情境当真实证据	通过	
说明修订理由	通过	
未整体重写（输出长度受控）	通过	回复长度 775

U5 项目评审

观察重点：标准明确；识别虚假/缺失证据；意见具体；评分或结论前后一致

校验项	结果	证据
输出结构化分维评价	通过	实得 5 个维度
识别无来源证据（证据缺口非空）	通过	实得 15 条缺口
识别「使用 AI」不能作为创新点	通过	integrity_risks=2 条
评分未虚高（无来源项目 < 50/100）	通过	实得 23.8/100
结论与证据一致（给出质量等级）	通过	
意见可执行（含修改建议）	通过	

U6 异常与降级

观察重点：不假装工具成功；错误可见；已有上下文不丢失；允许安全恢复；日志可定位

校验项	结果	证据
不支持的文件类型：返回明确错误而非假装成功	通过	HTTP 400 仅支持 PDF、DOCX、DOC 或 TXT 文件
文件无法解析：返回明确错误而非假装成功	通过	HTTP 422 无法提取文件文本，请检查文件是否为空或为扫描图片
会话不存在：返回明确错误而非假装成功	通过	HTTP 404 会话不存在，请重新开始
输入超长：返回明确错误而非假装成功	通过	HTTP 400 消息过长，请控制在 3000 字以内
评审输入过短：返回明确错误而非假装成功	通过	HTTP 400 评审至少需要 20 个字符的项目材料
学习问题为空：返回明确错误而非假装成功	通过	HTTP 400 请先输入一个学习问题
错误信息对用户可理解（非堆栈、含说明）	通过	

五、组内回归测试逐项结果

组内用例对应第二阶段**优化契约**中的问题编号，用于证明「承诺问题已修复」。

每条用例标明它回归的是哪一个已修复缺陷。

C-E01 证据分类默认值（无来源不判 F）

回归目标：回归：证据分类器默认把无来源陈述判为事实 F

校验项	结果	证据
「学校支持建立教材交易平台…」不判为 F	通过	实得 I
「社区已同意提供助餐场地…」不判为 F	通过	实得 I
「本项目已获得街道支持…」不判为 F	通过	实得 I

C-E02 有来源陈述判为 F

回归目标：回归：—（防止修复后过度保守）

校验项	结果	证据
有来源标记的陈述判为 F	通过	实得 F

C-E03 否定感知

回归目标：回归：关键词匹配对否定式失效

校验项	结果	证据
「没有调研」视为无证据	通过	
「依据调研」视为有证据	通过	
「无来源」视为无证据	通过	
否定句不产生证据命中	通过	

C-E04 评审评分门槛

回归目标：回归：无证据项目得到 87 分

校验项	结果	证据
无来源项目总分 < 50	通过	实得 23.8/100
质量等级为 0 或 1	通过	实得 1 严重缺陷
证据缺口非空	通过	实得 15 条
识别技术堆砌风险	通过	
创新维度被门槛封顶	通过	实得 6.0/20

C-E05 评审评分区分度

回归目标：回归：—（防止修复后过度收紧）

校验项	结果	证据
证据充分项目总分 >= 70	通过	实得 85.7/100
质量等级 >= 3	通过	实得 3 良好

C-F1-01 F1 概念覆盖

回归目标：回归：F1 仅有 2 个硬编码分支

校验项	结果	证据
知识库收录概念 >= 12 个	通过	实得 13 个
13 个常见概念全部命中	通过	全部命中

C-F1-02 知识库无编造来源

回归目标：回归：—（证据诚信）

校验项	结果	证据
无词条声称外部链接来源	通过	无
每个词条都有来源状态声明	通过	

C-L-02 版本可定位

回归目标：回归：无法确认 V2 相对什么版本优化

校验项	结果	证据
返回 agent_version	通过	2.1.0
返回 prompt_version	通过	2.1.0
返回 kb_version	通过	2.1.0
返回 git 提交号	通过	9f3236d
返回模型名	通过	deepseek-chat

C-S-01 日志脱敏

回归目标：回归：—（密钥与个人信息保护）

校验项	结果	证据
API Key 被脱敏	通过	key=sk- *REDACTED* phone= *PHONE* token- *REDACTED*
手机号被脱敏	通过	

C-X-01 降级透明

回归目标：回归：降级后仍记为 success，next_task 为空

校验项	结果	证据
响应标记 degraded	通过	degraded=True
降级原因可读	通过	LLM 调用失败 (APIStatusError)
降级下仍给出 next_task	通过	长度 233
运行状态记为 degraded 而非 success	通过	实得 degraded

C-L-01 日志字段完整性

回归目标：回归：日志仅有 run_id 与 flow

校验项	结果	证据
身份字段完整	通过	完整
时间字段完整	通过	完整
状态字段完整	通过	完整
行为字段完整	通过	完整
人机边界字段完整	通过	完整

C-H-01 人工干预可追溯

回归目标：回归：人工干预无处记录

校验项	结果	证据
可记录人工干预	通过	HTTP 200 total=1
非法干预类型被拒绝	通过	HTTP 400

C-P-01 本项目材料评审

回归目标：回归：—（大创项目材料自评）

校验项	结果	证据
总分为合理区间（50—100）	通过	实得 90.0
给出五个维度	通过	实得 5
识别出模拟/假设边界	通过	
建议可执行	通过	实得 4
未把无来源内容判为事实	通过	F=2（材料含统计公报来源，应至少命中 1 条）

六、关键回归对照（修复前 → 修复后）

缺陷	修复前表现	修复后表现	对应用例
无来源陈述被判定为「事实 F」	「学校支持建立教材交易平台」判为 F， <code>can_use_now=是</code>	判为 I（待核验），并给出核验动作	U2、C-E01
评审对无证据项目虚高打分	U5 输入得 87/100 ，证据缺口为空	同一输入得 23.8/100 ，等级 1（严重缺陷），证据缺口 15 条	U5、C-E04
关键词匹配对否定式失效	「无来源」因含「来源」被当作存在证据	否定感知生效，「没有调研」不再产生证据命中	U2、C-E03
降级后仍记为 success	LLM 失败后运行状态仍为 success， <code>next_task</code> 为空	状态记为 <code>degraded</code> ，原因可读， <code>next_task</code> 完整	U6、C-X-01
日志字段缺失	仅有 <code>run_id</code> / <code>flow</code>	补全身份、时间、状态、行为、人机边界五组字段	C-L-01

七、未通过项与待改进清单

手册明确要求**不得删除失败样本**。以下清单如实保留本次运行的全部未通过项。

本次运行**无未通过项**。

⚠ 但这**不等于系统没有问题**。自测只能证明「已定义的校验项通过」，无法覆盖未预想到的失败模式——用例由开发者自己设计，存在自证偏差。因此本报告的全部结论仅在「已定义的校验项」范围内成立。

八、本次测试的局限（诚实声明）

- 存在自证偏差**。全部用例均由开发者自行设计，容易只覆盖自己预想到的问题；覆盖范围之外的行为未经检验。
- LLM 路径未被充分覆盖**。测试时 DeepSeek API 返回 402（Insufficient Balance），因此 F2 项目指导始终运行在本地确定性降级模式下。LLM 主路径的行为**未经验证**。
- F1/F3 为确定性引擎**，其输出不随采样变化，因此重复运行结果的方差极小，

但这**不代表**在更广泛输入上的稳定性已被证明。

4. **测试输入规模有限。**统一测试集仅 6 个用例，组内测试 13 个用例，覆盖的是已识别的问题，不能代表全部失败模式。
5. **未进行真实用户测试。**课程不要求真实调研，本报告中的所有用户相关判断均为假设，不得作为市场证据使用。

本报告由 [deliverables/build/generate_selftest.py](#) 依据原始测试结果自动生成，生成时间 2026-09-15 00:20。

原始结果未经任何筛选，全部保留在 [tests/reports/](#) 目录下。