

小组总结

课程阶段：第一阶段（基线诊断）→ 第二阶段（V2 迭代）→ 第三阶段（综合应用）

项目名称：食刻准 —— 社区老年助餐的需求预测与营养约束备餐辅助系统

Agent 系统：双创智能教练 V2.1.0

一、我们做了什么

本次课程包含两条并行的线：一条是**大创项目线**，一条是 **Agent 工程线**。两条线的共同任务是：在真实的立项过程中，让 Agent 暴露问题，再把问题修好。

1.1 大创项目线

选题为「社区老年助餐的需求预测与营养约束备餐辅助系统」，方向属社会治理和公共服务。

项目要解决的问题是：**社区助餐点经营者无法预知次日有多少老人来吃饭，只能凭经验备餐，导致备餐不足与食材浪费同时存在。**

我们完成的工作：

阶段	产物
选题	3 个候选选题 + 决策矩阵（7 指标加权评分）
论证	证据与假设台账（24 条结论，全部标注 F/I/H/S）
立项	一页项目立项说明书、用户与场景分析、关键假设与验证计划
方案	核心机制设计、4 种替代方案比较、单位经济测算、三情景财务
风险	7 类风险识别、合规与伦理边界、能力缺口声明

证据基础：取得 A 级权威来源 2 项（民政部《2023 年民政事业发展统计公报》、民政部等 11 部门《积极发展老年助餐服务行动方案》民发〔2023〕58 号），B 级来源 4 项（人民日报《健康时报》、青岛日报、华商报、重庆日报）。

1.2 Agent 工程线

从 V1 出发，通过真实使用暴露问题，完成 V2 迭代。

指标	数据
识别缺陷总数	13 项（P0 阻断 3 项、P1 严重 6 项、P2 一般 4 项）
纳入 V2 修复	12 项
明确延期	1 项（见《04_智能体迭代开发文档》延期项）
新增测试用例	统一测试集 U1—U6（35 项校验）+ 组内回归 13 例（42 项校验）
自测通过率	77/77，100%

二、最重要的三件事

2.1 我们差点把「编造」写进了系统里

回顾整个过程，最危险的发现不是某个功能不好用，而是 **V1 的证据分类器会把没有任何来源的陈述判为「事实 F」，并标记为「可以直接采用」。**

测试时输入「学校支持建立教材交易平台」——这句话没有任何来源——系统给出的标签是「事实：已有可定位来源或明确材料支持」，可用性为「是」。

这意味着：如果学生直接使用这个输出，就会把一个凭空断言写进立项材料，并且带着系统背书的「事实」标签。

这个问题不能靠「改改提示词」解决，因为它出在兜底逻辑上。 我们重建了分类器，把默认值从「F」改成「推断/待核验」，并要求 F 必须有明确的来源标记才能成立。同时对「无来源」「没有调研」这类否定式表述做了专门处理——原来的关键词匹配会因为「无来源」字面包含「来源」而把它当作存在证据。

2.2 我们发现了自己的「好评倾向」

同一批修复前，F3 评审流程给一个明确写着「无来源」「创新点是使用 AI」「盈利依靠广告」的项目打了 **87 分**，而且证据缺口列表是空的。

修复后，同一个输入得 **23.8 分**，质量等级 1（严重缺陷），证据缺口 15 条，并主动提示了两条诚信风险。

这个反差让我们意识到：一个打分系统如果只做「关键词有没有出现」的匹配，它实际上是在**奖励会堆词的人**，而不是奖励有证据的人。我们因此给评分加了证据门槛——全篇没有可定位来源时，任何维度不得超过满分的 40%；创新点如果只落在技术采用上，创新维度不得超过 30%。

2.3 我们学会了把「不好看」的东西留下来

课程手册反复强调：不得删除失败样本、不得把人工成果记成 Agent 能力、降级必须如实标注。

我们在实现中把这条落到了具体的地方：

- LLM 服务不可用（API 余额不足）时，系统会**如实标记为`degraded`状态**，而不是继续记录成功；用户在界面上也会看到「当前运行于本地确定性模式」的提示。
- 我们**没有删除**那 4 个最初未通过的测试项，而是修好它们并保留了修改记录。
- 我们的证据台账里保留了**对自己不利的条目**——例如「核心问题判断目前只有 B 级证据支撑」，以及「微信群接龙预订已经解决了部分问题，这是我们必须承认的现有做法」。

三、遇到的困难与怎么解决的

困难	表现	解决方式
LLM 服务不可用	DeepSeek API 返回 402（余额不足），所有大模型调用失败	把架构改为「确定性引擎为主、LLM 为可选增强」。F1/F3 完全不依赖大模型，F2 降级后仍输出完整结构并如实标注
自我测评的偏差	自己设计的测试用例，容易只覆盖自己想得到的问题	明确在报告中写出这一局限，不把「自测全通过」表述为「系统没问题」
评分标准的主观性	最初用关键词命中就给分，结果明显失真	改为「必备证据命中比例 + 证据门槛封顶」，并把评分口径写进输出，使结论可复核
证据收集的边界	权威来源只支撑人口规模与政策要求，支撑不了「浪费严重」这一具体判断	如实写出这个缺口，把比例类数字全部标注为「媒体报道转述」，不做外推

四、我们做得不够的地方（诚实清单）

1. **自测存在自证偏差。**全部测试用例由我们自己设计，因此只能覆盖我们已经想到的问题；我们没想到的失败模式，测试是抓不到的。「77/77 通过」只说明已定义的问题都修好了，不说明系统没有别的毛病。
2. **LLM 主路径未经验证。**由于 API 余额问题，F2 的大模型路径始终没有在有效额度下运行过。我们验证的是降级路径。
3. **F1/F3 没有会话归属。**这两个流程的对话记录不进入服务端会话，教师端看不到学生在这两个流程中的使用情况。已列入延期项。
4. **大创项目的核心问题判断证据等级偏低。**A 级来源只支撑人口规模和政策方向，不支撑「备餐浪费严重」这一具体结论，后者目前只有 B 级支撑。
5. **营养约束部分只有概念设计。**团队缺少营养学专业能力，在营养师顾问到位前，这部分不产生任何面向真实老人的饮食建议。
6. **商业模式偏弱。**单位经济测算显示单点年收入约 4320 元，客单价很低，第一年在悲观情景下明确亏损。

五、收获

- **学会了区分「看起来对」和「有证据」。**一个系统输出流畅、结构完整、看起来专业，和它说的东西有依据，是完全不同的两件事。
- **理解了降级设计的重要性。**系统在依赖项失效时的行为，比它在一切正常时的表现更能说明它是否可靠。
- **认识到诚实记录的成本与价值。**把失败、降级、延期、能力缺口如实写出来，短期内让材料「不好看」，但它让整个论证变得可信——这正是这门课真正在训练的东西。

六、后续计划

优先级	事项
1	扩大测试输入范围并请组外同学试用，降低自证偏差
2	用助餐点历史台账做需求预测的回溯测试，验证核心机制
3	实地观察 2—3 天，验证最危险的假设 H-17
4	补齐 F1/F3 的会话归属，使教师端能看到完整使用记录
5	联系营养师顾问，把营养约束从概念设计推进到规则设计
6	在 LLM 额度恢复后，补测 F2 的大模型主路径